


从模型API调用到Agent配置



API: Application Programming Interface

即程序之间的接口

例如，C语言 API 以函数的形式呈现，例如 printf()、scanf() 等

API为我们提供了一个功能实现的接口，在你不需要知道功能具体怎么实现的情况下，你可以使用他们的功能

去年流行的说法“接入deepseek”就是典型的调用API的案例



注意：API和网页端对话不一样，API是要收费的，即使网页端免费、API也是收费的

网页端的 AI 只能提供对话式的服务：你问它答，人在中间当传话筒。

而通过 API，我们可以让程序自己调用 AI 的能力，把我们的平台包装得更智能，真正“结合 AI”。（现在比赛的趋势大体就是这样，评委看你有没有把 AI 落到系统里，会看你和AI的结合程度，当然仅仅只是接入API还不够亮眼）

在正式动手接入之前，我们首先要了解可以接入的 AI 有哪些。

除了豆包、大家主流使用的**大模型**主要是以下几个：

- 国内：[DeepSeek](#)、[通义千问 \(qwen\)](#)、[智谱清言 \(glm\)](#)、[Kimi](#)

- 国外：[chatGPT](#) 、[Claude](#) 、[Gemini](#)  **【节点不干净可能进不去】**


其中，claude (claude code)、gpt (codex) 的代码能力较强，国内可用glm5.1等coding plan进行平替，除了coding plan以外，这里介绍性价比比较高的方案：接入新出的deepseek V4 pro的API，开思考强度max，调整成高缓存命中率的设置。

涉及设计（包括图片生成、前端UI设计等）Gemini强[当然最近比较火的gpt-image-2在生图的设计方面优势更大]，其他AI也可以做简单的前端设计，但是各自有各自的风味。

【补充几个概念：一般常说的“大模型”，严谨来说叫**LLM（大语言模型）**，它本质上只会处理文字。你扔给它一段话，它回你一段话。

网页端虽然也叫大模型，但他们能传图、语音，本质上是**多模态模型**，


而根据要求生图、生视频，则是**扩散模型（SD、Stable Diffusion）**在工作。



Agent = LLM (大脑) + Planning (规划) + Tool use (执行) + Memory (记忆)。

所以：一个网页端既能聊天、又能生图、还能做PPT，是不是就是 Agent了？

不是。这只是“功能集成”，你让它生图它调绘画模型，你让它做PPT它调排版模型，每一步都需要你手动发出指令。而真正的 Agent 是自己规划步骤、自己调用工具、自己检查结果，你只给一个需求，中间过程全由AI自己规划完成。



AI 编程代理 (Coding Agents)，有人也叫脚手架，更多人叫agents。

主流的 agents 分为以下三类：

- **CLI Agent (命令行智能体)**
- **IDE Agent (编辑器内嵌智能体)**
- **Agent Harness / Framework (智能体框架或“脚手架”)**

大家听得比较多的、主流的agents主要是：

claude code (Claude)、codex (gpt)、Cursor、GitHub Copilot

其中，claude code就是典型的**CLI Agent (命令行智能体)**，通过在终端输入claude就可以激活（首先需要cd进入项目文件夹），codex cil也是此类。

Cursor和GitHub Copilot属于**IDE Agent**，在编辑器里用。区别在于：Cursor是一家独立公司做的AI-first 编辑器，可以自由切换Claude、GPT等模型，因为和vscode的开发环境很像，大家衔接也比较丝滑，所以在当时也更受青睐；Copilot是微软出品，和GitHub 生态无缝衔接，直接以插件的形式接到github里（但是这一阵子copilot限额很厉害，并且暂停了 Pro、Pro+、学生计划的注册，仅pro+可以使用Opus系列模型【Opus是最为顶配的Claude系列模型，还有sonnet（日常）、haiku（快速）模型】）。

至于Codex，如果你有GPT plus/pro会员，在gpt网页端一键导入到vscode里的就是**Codex IDE**。

安装CLI一类的agent基本上可以通过**npm**指令一键下载，但是**前提是你的电脑要有 Node.js 环境**（npm 是 Node.js 自带的包管理器）。大部分 CLI Agent 都用 TypeScript/JavaScript 写的，所以天然用 npm 分发。如果你装的是 Python 写的 Agent（比如 Aider），那就得用 pip 安装，不是非得 npm 不可。

Agent Harness / Framework (智能体框架) 是另一个维度的概念，它不是一个编辑器或命令行工具，而是一套用来搭建和编排 Agent 的程序框架。

你可以把 CLI Agent 和 IDE Agent 理解为“开箱即用的成品工具”，

而 Framework 是"造工具用的工具箱": 你可以用它自己搭一个 Agent 出来, 定义它有哪些工具、怎么规划步骤、出错了怎么重试、多个 Agent 之间怎么协作。

典型的框架有 LangChain、LangGraph 等。

这类框架更多出现在需要自定义复杂工作流的场景, 比如"让 Agent A 写代码、Agent B 做 review、Agent C 跑测试, 三者自动流转", 这种流程用 CLI Agent 就没法直接实现, 得靠 Framework 来编排。对于agent深度定制化那些项目来说, 如果你想让 AI 能力深度嵌进你系统的业务流程里, Framework 这个方向是值得了解的。

今天课程的实操内容主要在于安装Claude Code (有vscode for claude code和claude code (cli) 两种选择), 并且用deepseek做平替替代claude API。

先简单介绍一下Claude Code (claude code cli)。是Anthropic推出的 AI 编程工具, 直接在终端里运行, 你跟它聊天描述需求, 它就能自主分析项目、写代码、跑命令、修 Bug, 全程自主执行。

直接装claude code cli, 有的同学可能欠一些基本环境, 如果不欠环境的话, 可以试试直接在终端运行下面这个代码就能装好:

```
npm install -g @anthropic-ai/claude-code
```

*确保你的电脑有 Node.js 环境和 npm 软件依赖安装工具, 没有的话, 直接到[Node官网](#)下载傻瓜式安装包, 最好下载新一些的, 至少20+, 详细教程可以查看最后面的教程链接

这边优先介绍一种替代方案 (如果你不想折腾命令行), **这里推荐的入门方式是, 先装 VS Code 插件** (GUI, 区分与命令行的CLI), 它有图形界面, 配置简单。但CLI更轻量且速度快, 更适合专业开发。

	CLI (命令行界面)	GUI (图形用户界面)
怎么操作	用键盘敲命令, 纯文字交互	用鼠标点击按钮、菜单、拖拽窗口
长什么样	黑底白字的终端窗口	有图标、按钮、窗口的图形界面
典型例子	终端/Terminal、CMD、PowerShell	VS Code、浏览器、微信、Windows桌面
优点	轻量、速度快、容易自动化、可以批量处理、不占资源	直观、上手快、视觉反馈清晰、适合新手
缺点	需要记命令, 对新手不友好	占资源, 有些复杂操作不如命令行灵活

两者可以共存, 共享同一套配置 (CCSwitch的配置), 这里介绍VSCode插件:

- vscode插件接入claude code:

[一键下载](#)

就装好了。

Claude Code 本身是支持切换模型的，你可以通过「修改环境变量」或「编辑配置文件」来对接其他大模型的 API。

一般你使用哪家的大模型 API，直接看对应的官方文档，就能找到接入方法。

但是有的时候光接入还不够，模型的**缓存命中率**不高，会导致花费较大，下面的配置包含了一些调整缓存命中率的配置

[缓存命中率是什么？

你第一次让AI看你整个项目的代码，它得从头到尾读一遍，费token。

但是你**第二次再问它**，如果你的项目代码没怎么变，AI其实可以**偷懒**——它把你上次已经读过的内容存下来了，直接拿过来用，不用再重新啃一遍。这个“直接拿上次存好的来用”，就叫**缓存命中**。

那缓存命中率，就是**10次提问里有几次能直接复用之前的结果**。

而deepseek在适当调整后，缓存命中率可达98%以上。

这是一开始没调缓存命中率的（后面开了，所以命中缓存也多了，但是未命中的那些也挺贵的）：



这是调过后的：



价格，一个二十多，一个4块多




]

所以说很有必要去做调整

下一步是接入deepseek的API key，替换掉claude code脚手架的模型。


如何套壳接入deepseek的API key，让我们使用





1.打开setting.json配置基础环境

(1) 打开setting



(2) 确保光标在此处后面闪烁

```
"claudeCode.disableLoginPrompt": true,  
"claudeCode.environmentVariables": [
```

```
]
```

(3) 在后面中括号内写一些设置。

在写设置前，确保自己已经有deepseek的API：

[DeepSeek | 深度求索](#)

🚀 DeepSeek-V4 预览版本发布，具备世界顶级推理性能，Agent 能力大幅提高，已在网页端、APP 和 API 上线，点击查看详情。

deepseek

探索未至之境

开始对话

与 DeepSeek 免费对话
体验全新旗舰模型

API 开放平台

调用 DeepSeek 最新模型
快速集成、流畅体验

deepseek

开放平台

用量信息

API keys

充值

账单

接口文档

常见问题

产品定价

实用集成

联系我们

个人信息

网页版免费对话 ↗

服务状态 · 开放平台协议 · 隐私政策

· 浙ICP备2023025841号 ·

浙公网安备 33010502011812 号

列表内是你的全部 API key，API key 仅在创建时可见可复制，请妥善保存。不要与他人
码中。为了保护你的帐户安全，我们可能会自动禁用我们发现已公开泄露的 API key。我
况进行追踪。

创建 API key

粘贴下来，填在下面对应的地方：

```
"claudeCode.environmentVariables": [  
  
  {  
    "name": "ANTHROPIC_BASE_URL",  
    "value": "https://api.deepseek.com/anthropic"  
  },  
  {  
    "name": "ANTHROPIC_AUTH_TOKEN",  
    "value": "需要填入ds那获取的API key"  
  },  
  {  
    "name": "ANTHROPIC_MODEL",  
    "value": "deepseek-v4-pro[1m]"  
  },  
  {  
    "name": "ANTHROPIC_DEFAULT_OPUS_MODEL",  
    "value": "deepseek-v4-pro[1m]"  
  },  
  {  
    "name": "ANTHROPIC_DEFAULT_SONNET_MODEL",  
    "value": "deepseek-v4-pro[1m]"  
  }  
]
```


```


    },
    {
      "name": " ANTHROPIC_DEFAULT_HAIKU_MODEL",
      "value": "deepseek-v4-flash"
    },
    {
      "name": " CLAUDE_CODE_SUBAGENT_MODEL",
      "value": "deepseek-v4-flash"
    },
    {
      "name": " CLAUDE_CODE_EFFORT_LEVEL",
      "value": "max"
    },
    {
      "name": "CLAUDE_CODE_DISABLE_AUTO_TITLE",
      "value": "1"
    },
    {
      "name": " CLAUDE_CODE_DISABLE_NONESSENTIAL_TRAFFIC",
      "value": "1"
    },
    {
      "name": " CLAUDE_CODE_DISABLE_SESSIONMETADATA",
      "value": "1"
    },
    {
      "name": "CLAUDE_CODE_DISABLE_QUOTA_CHECK",
      "value": "1"
    }
  ]

```

到这一步就可以结束了，已经完成了最基础的接入。

可以检验一下：






在此页面可以稍微测试一下，正常响应就说明接好了。

【这种改setting的方式其实比较繁琐，如果每次切换成另一个模型都要改一遍setting，很麻烦。实际上可以使用CCSwitch对setting进行管理，可以比较便捷地管理多种agent】




vscode插件的claude code配好了，但是在这个页面没法流畅地使用指令下载skill，



接好agent后，可以通过下面这种方式在没有通过npm安装Claude Code的情况下启用终端：

勾选，启用终端




找到刚刚扩展的下载目录

C:\Users\你的用户名\.vscode\extensions\anthropic.claude-code-2.1.140-win32-x64\

* Users可能显示的是“用户”

* 复制这个路径

1. 左下角搜索直接搜env，回车
2. 点击「环境变量」
3. 在「系统变量」里找到 Path，点击编辑
4. 添加刚刚复制的路径



重新打开vscode后，这一插件就能在终端和claude code cli那样使用了。

VS Code 扩展将 Claude CLI 嵌入到 IDE 中，共享同一套 `~/.claude/` 配置体系

其中详细地址在用户文件夹下的 `.claude/settings.json` 中

安装vscode 插件虽然便捷，但是有部分功能体验起来并没有那么流畅（比如说安装skill），此时直接安装claude code cli，会比较方便：

Windows系统的话，需要先确保有git，Node.js（最好装新一些的，至少20+）等基础配置

[2026 最新 Claude Code 配置教程：从安装到 API 接入全流程 - 知乎](#)

或者中文站的官方文档：[Claude Code 安装 - 快速开始 | Claude Code 中文站](#)

在以上教程都完成的前提下，就能比较流畅地给agents加各种组件辅助开发了，

建议先通过`/plugin`命令添加官方技能市场，相当于装了个技能商店：


```
/plugin marketplace add anthropics/skills
```

还可以安装skill，比如Firecrawl（联网搜索和网页抓取工具），Context7（技术文档查询工具，让AI能获取到各种框架和库的最新官方文档，避免用过时的API文档写代码）

有些情况skill无法弥补的功能，需要通过MCP来补充，比如说扫描pdf比较好的paddle ocr等等。

skill、MCP、plugin，这三个概念有点容易混淆，本质上都是在做“让接入的AI长出手脚”，但三者完全不一样。

前两者看图还能理解一些：





skill，本质上是一段存在 .claude/skills/ 目录下的**提示词文档**（Markdown 文件，就和这个课件一样），告诉 AI "遇到这类任务应该怎么做、有什么注意事项、用什么流程"。

它不给 AI 新增能力，只是优化 AI 做某件事的方式。比如说我们常在网页端不厌其烦和AI说的：生成完整的代码，不要修改我原有的函数，不要改变变量名。这种“形式规范”就是skill（只不过skill往往也涉及领域方面的专业知识、业务流程）。

MCP，可以看成是AI世界的USB 接口，MCP服务器本质上是一个独立运行的小程序，它把某个外部能力（比如操作文件系统、调用数据库、发 HTTP 请求、控制浏览器）包装成 AI 能理解的工具调用格式。AI 就可以借来使用这些外部能力。

而**Plugin (插件)**，在这里，指的是Claude Code 里 /plugin命令，一个 Plugin可以打包进去一批 Skill、配置、甚至MCP 服务器的引用。

对于claude code其实还是会使用到一些指令（即使是GUI的vscode插件），以及它的页面也主要为英文，



这两个其实比较重要，memory可以查看、编辑 Claude 对你项目和个人偏好的"记忆"，permissions可以给他下权限控制，比如能不能直接删文件、能不能执行shell 命令、能不能访问某些目录。

这里放一些常用指令（其实在vscode下拉处也能看到）：

/init 项目初始化（会生成{项目根目录}/CLAUDE.md，相当于claude code对这个项目文件夹的概括，说明书，但是总字数尽量控制在 500 字以内，太多了效果不好变好）【区分于全局 CLAUDE.md的是，这个/init创建的更像是本项目的说明书、注意事项，全局CLAUDE.md是跨项目通用的个人偏好和习惯，比如说

回答偏好
- 回复使用中文

】

/compact 压缩上下文，对话变长、变慢时使用

/context 查看上下文使用情况，看看是不是要压缩对话了

/memory 查看和编辑所有记忆内容，在编辑器中可以删除不准确的条目，以免agent走偏

/skills 管理skill开与关

/btw +问题 快速提问不污染上下文（需要问这个问题，但不想让这次问答进入对话历史，也不想新开一个窗口）

/config 查看、修改配置

@main.py 引用文件（可以有多个）

@src/ 分析项目结构并给出优化建议（引用整个目录）

PS：这边附上一些好用的工具

[图吧工具箱官方网站 - DIY爱好者的必备工具合集](#) 清理C盘好用

[AI API中转站收录与评测](#) 测评API中转站非常好的网站